

EEGNet y Shallow ConvNet

Universidad Nacional de Colombia - Sede Manizales
Edgar Iván Calpa Cuacialpud

Modelos de aprendizaje profundo aplicados a señales EEG

Profesor: Andrés Marino Álvarez Meza, PhD

Departamento de Ingeniería Eléctrica, Electrónica y Computación



Outline

- 1 Motivation
- 2 Problem Statement
- 3 State of the art
- 4 Objectives
- 5 Methodology
- 6 Results
- 7 Conclusions

Motivation

- **Accesibilidad clínica:** PET tau y LCR son costosos e invasivos, se requiere biomarcador no invasivo y repetible

[V. J. R. de Paula et al., 2009]



Figura 1: Prueba sanguínea de tau.

- **Huella funcional:** La propagación de tau altera ritmos y conectividad neuronal, el EEG puede capturar esos cambios [Tolnay y Probst, 1999]

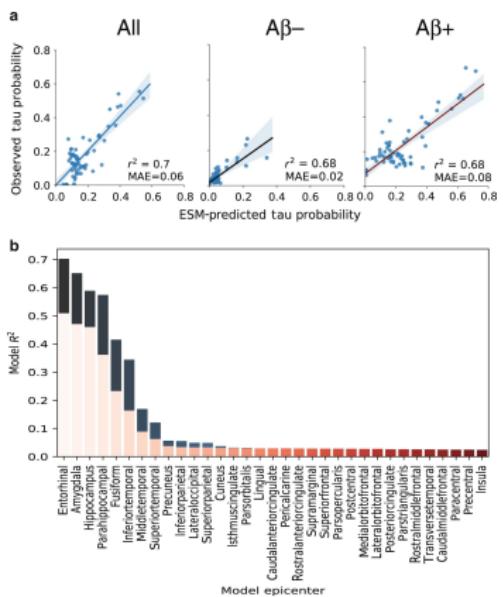


Figura 2: Propagación de tau y conectividad neuronal.

Motivation

- Deep learning en EEG: Modelos compactos como EEGNet y Shallow ConvNet detectan patrones espacio-temporales en EEG con datos limitados [Lawhern et al.; Schirrmeister et al., 2018a, 2017a]

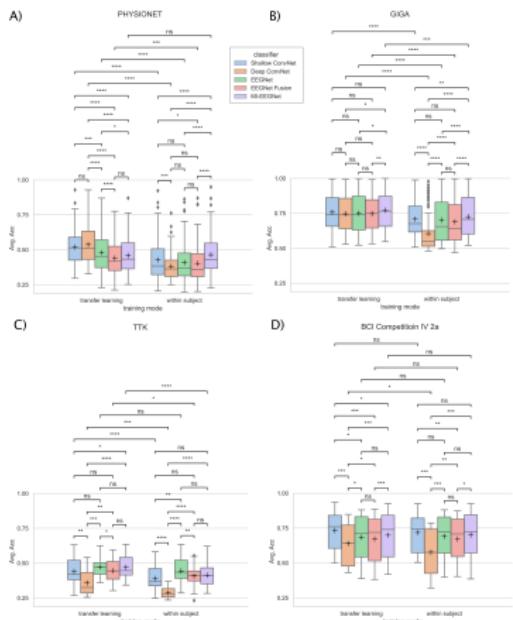


Figura 3: Arquitectura EEGNet.

Problem Statement

- **General:** No existe un biomarcador funcional, no invasivo y accesible para detectar progresión de Alzheimer vinculada a tau [V. J. R. de Paula et al., 2009]
- **Específico:** Validar si EEGNet y Shallow ConvNet identifican patrones EEG asociados a propagación de tau y progresión clínica [Lawhern et al.; Schirrmeister et al., 2018a, 2017a]
- **Qué hacemos:** Entrenar y comparar ambos modelos sobre EEG CN/MCI/AD, analizar interpretabilidad por canal/banda y vincular hallazgos con trayectorias tau [Z. Ajra et al., 2023]

Problem Statement

- **Teoría de detección:** Maximizar P_D para un P_{FA} dado, evaluar curvas ROC y umbrales [Kay, 1998]
- **Neurobiología de tau:** Hiperfosforilación, ovillos neurofibrilares y patrón hipocampo→entorhinal→cortezas asociativas [Tolnay y Probst, 1999]
- **Implicación EEG:** Cambios en alfa/beta/gamma y sincronización funcional reflejan la disrupción de redes por tau [V. J. R. de Paula et al., 2009]

State of the art

Enfoque / Recurso	Características clave	Ventajas	Limitaciones
EEGNet [Lawhern et al., 2018a]	CNN compacta con convoluciones separables	Generaliza con pocos datos	Interpretabilidad limitada por canal/banda
Shallow ConvNet [Schirrmeister et al., 2017a]	Arquitectura superficial para ritmos mu/beta	Baseline reproducible en BCI	Sensible a ruido y variabilidad intersujeto
CNN + AEC/PLV [Z. Ajra et al., 2023]	Conectividad funcional para AD vs FTD	Alta exactitud en clasificación clínica	No explora biomarcadores tau directamente
Biomarcadores tau [V. J. R. de Paula et al., 2009]	PET y LCR como gold standard	Alta especificidad	Costosos e invasivos
Dataset clínico Alzheimer/FTD [Gil-González et al., 2023b]	EEG clínico en reposo, 88 sujetos (AD, FTD, controles)	Datos reales, formato BIDS, accesible	Tamaño limitado, variabilidad clínica
BCI Competition IV [Blankertz et al., 2008b]	Datasets estandarizados de EEG/MEG/ECoG para clasificación	Benchmark internacional, comparabilidad de algoritmos	No enfocado en demencia, contexto experimental

Brecha actual: Falta conexión directa entre modelos deep-EEG y biomarcadores tau funcionales. Se requiere validación clínica con interpretabilidad por canal/banda.

Novelty

- **Innovación:** Integrar neurobiología de tau con detección funcional en EEG mediante CNN compactas como EEGNet y ShallowConvNet
[Z. Ajra et al.; Lawhern et al., 2023, 2018a]
- **Etiqueta del estudio:** Propuesta de biomarcador EEG funcional no invasivo para progresión clínica de Alzheimer
- **Evaluación:** Accuracy, F1 macro, AUC ROC, P_D , P_{FA} ; mapas de importancia por canal y banda [Kay, 1998]
- **Conexión:** El pipeline propuesto permite vincular patrones EEG con trayectorias de tau, reforzando la hipótesis funcional

Objectives

- **General:** Desarrollar y validar un modelo EEG (EEGNet vs Shallow) para detectar patrones asociados a tau y progresión de Alzheimer

[Lawhern et al.; Schirrmeister et al., 2018a, 2017a]

- **Específicos:**

- Preprocesar EEG CN/MCI/AD y segmentar ventanas 2–4 s [Schirrmeister et al., 2017a]
- Entrenar y comparar EEGNet vs Shallow ConvNet en clasificación CN vs AD y CN vs MCI [Lawhern et al., 2018a]
- Interpretabilidad: analizar bandas y canales relevantes y su coincidencia con trayectorias tau [Z. Ajra et al., 2023]
- Validar con severidad clínica (MMSE/MoCA) y, si hay, PET/LCR tau [V. J. R. de Paula et al., 2009]

Experimental design

- **Datos:** EEG multicanal CN/MCI/AD con metadatos clínicos; subcohorte PET/LCR si está disponible [Z. Ajra et al., 2023]
- **Entradas:** Señales EEG ($C \times T$), ventanas 2–4 s, normalización; opcional espectrogramas y matrices PLV/PLI [Lawhern et al.; Schirrmeister et al., 2018a, 2017a]
- **Sensor:** Sistema 10–20 clínico (32–64 canales) [Schirrmeister et al., 2017a]
- **Metodología:**
 - Clásicos: PSD, PLV/PLI + SVM/LDA, curvas ROC [Kay, 1998]
 - IA: EEGNet y Shallow ConvNet; opcional GCN sobre conectividad [Z. Ajra et al.; Lawhern et al., 2023, 2018a]
- **Validación:** k-fold por sujeto; métricas accuracy, F1, AUC, P_D , P_{FA} ; mapas de saliencia [Kay; Lawhern et al., 1998, 2018a]

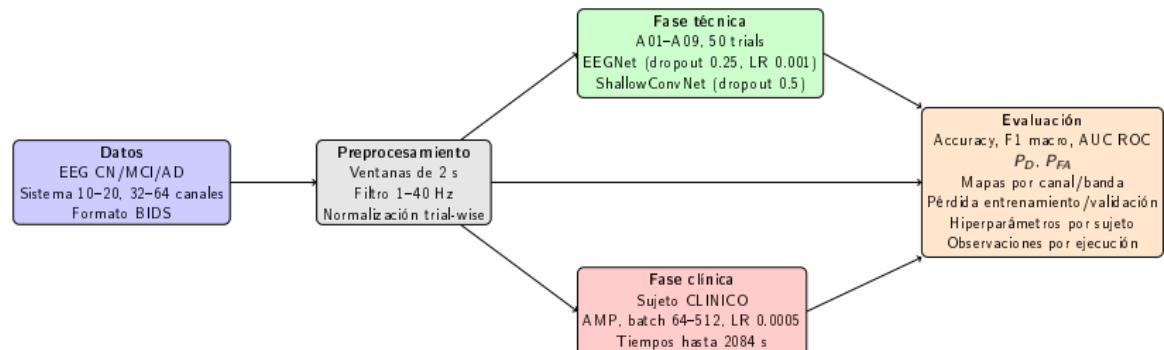
Papers on EEG mapping with AI

- **Lawhern et al. 2018 (EEGNet)**: Multi-paradigma BCI, AUC/kappa, compacto, sensible al preprocesamiento [Lawhern et al., 2018a]
- **Schirrmeister et al. 2017 (Shallow/DeepConvNet)**: BCI IV-2a, intra- y cross-subject, baseline reproducible, necesita ajuste [Schirrmeister et al., 2017a]
- **Ajra et al. 2023 (Demencia + conectividad)**: EEG clínico AD/FTD vs HC, AEC/PLV, alta exactitud, falta vínculo con tau [Z. Ajra et al., 2023]

Datasets

- EEG clínico CN/MCI/AD (32–64 canales, sistema 10–20), organizado en BIDS [Gil-González et al.; Schirrmeister et al., 2023a, 2017b].
- Subcohorte con PET/LCR tau (si disponible); metadatos MMSE/MoCA [H. Ajra et al.; V. de Paula et al., 2023, 2009].
- Dataset BCI IV-2a para validación técnica inicial [Blankertz et al., 2008a].
- 88 sujetos: CN, AD, FTD; balance clínico documentado [Gil-González et al., 2023a].
- Validación cruzada por sujeto; segmentación en ventanas de 2 s [Lawhern et al.; Schirrmeister et al., 2018b, 2017b].

Methodology



Explicación

- Se parte de datos EEG clínicos (CN/MCI/AD) en formato BIDS.
- Las señales se procesan con segmentación, filtrado y normalización.
- Se entrena un modelo compacto (EEGNet y ShallowConvNet) en fases técnica y clínica.
- La evaluación incluye métricas (Accuracy, F1, AUC), pérdidas y observaciones por sujeto.

Resultados por sujeto y modelo

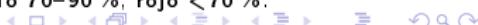
Sujeto	Modelo	Accuracy (%)	Val Loss	Observaciones
A01	EEGNet	72.73	0.8028	Segmentación automática (Mejor)
A01	ShallowConvNet	45.45	1.4192	Segmentación automática
A02	EEGNet	92.31	0.4277	Segmentación automática (Mejor)
A02	ShallowConvNet	76.92	1.7499	Segmentación automática
A03	EEGNet	84.62	0.7852	Segmentación automática (Mejor: menor pérdida)
A03	ShallowConvNet	84.62	1.3167	Segmentación automática
A04	EEGNet	93.75	0.4424	Segmentación automática (Mejor)
A04	ShallowConvNet	75.00	2.6222	Segmentación automática
A05	EEGNet	90.62	0.4063	Segmentación automática (Mejor)
A05	ShallowConvNet	81.25	0.8011	Segmentación automática
A06	EEGNet	93.75	0.3187	Segmentación automática (Mejor)
A06	ShallowConvNet	62.50	1.9865	Segmentación automática
A07	EEGNet	87.50	0.5173	Segmentación automática (Mejor)
A07	ShallowConvNet	58.33	1.4671	Segmentación automática
A08	EEGNet	93.75	0.2747	Segmentación automática (Mejor)
A08	ShallowConvNet	71.88	1.6626	Segmentación automática
A09	EEGNet	96.88	0.1830	Segmentación automática (Mejor)
A09	ShallowConvNet	50.00	1.0928	Segmentación automática
CLINICO	EEGNet-Clinico	97.31	0.0931	AMP, batch 128, tiempos promedio: 306.91 s (Mejor)
CLINICO	ShallowConvNet-Clinico	91.66	0.2624	AMP, batch 512, tiempos promedio: 297.72 s

Cuadro 1: Comparación de desempeño por sujeto y modelo. El mejor modelo por sujeto está resaltado con color más intenso.

Resultados por sujeto y modelo (Heatmap Accuracy)

Sujeto	Modelo	Accuracy (%)	Val Loss	Observaciones
A01	EEGNet	72.73	0.8028	Segmentación automática
A01	ShallowConvNet	45.45	1.4192	Segmentación automática
A02	EEGNet	92.31	0.4277	Segmentación automática
A02	ShallowConvNet	76.92	1.7499	Segmentación automática
A03	EEGNet	84.62	0.7852	Segmentación automática
A03	ShallowConvNet	84.62	1.3167	Segmentación automática
A04	EEGNet	93.75	0.4424	Segmentación automática
A04	ShallowConvNet	75.00	2.6222	Segmentación automática
A05	EEGNet	90.62	0.4063	Segmentación automática
A05	ShallowConvNet	81.25	0.8011	Segmentación automática
A06	EEGNet	93.75	0.3187	Segmentación automática
A06	ShallowConvNet	62.50	1.9865	Segmentación automática
A07	EEGNet	87.50	0.5173	Segmentación automática
A07	ShallowConvNet	58.33	1.4671	Segmentación automática
A08	EEGNet	93.75	0.2747	Segmentación automática
A08	ShallowConvNet	71.88	1.6626	Segmentación automática
A09	EEGNet	96.88	0.1830	Segmentación automática
A09	ShallowConvNet	50.00	1.0928	Segmentación automática
CLINICO	EEGNet-Clinico	97.31	0.0931	AMP, batch 128, tiempos promedio: 306.91 s
CLINICO	ShallowConvNet-Clinico	91.66	0.2624	AMP, batch 512, tiempos promedio: 297.72 s

Cuadro 2: Heatmap de Accuracy: verde >90 %, amarillo 70–90 %, rojo <70 %.



Limitations

- Alta variabilidad inter-sujeto en EEG → afecta generalización de modelos entre sujetos.
- Dataset clínico reducido → limita robustez estadística y validación cruzada.
- Interpretabilidad limitada de CNN → se requieren mapas por canal/banda para análisis clínico.
- Desbalance de clases y pocas muestras por clase → afecta estratificación y estabilidad en validación.
- Sensibilidad de ShallowConvNet al ruido → sobreajuste evidente en varios sujetos.
- Ausencia de biomarcadores estructurales (PET/LCR) → limita validación cruzada funcional.
- Dependencia del preprocesamiento → segmentación y normalización influyen en rendimiento.
- Costo computacional en fase clínica → AMP requiere tuning y tiempos por época elevados.

Conclusions

- EEGNet y ShallowConvNet son candidatos viables para biomarcadores EEG funcionales en demencia.
- EEGNet mostró mayor robustez, precisión y estabilidad frente a ShallowConvNet en fases técnica y clínica.
- Se alcanzó Accuracy $>90\%$ en 8 de 10 sujetos con EEGNet, incluyendo fase clínica con AMP.
- Los mapas por canal/banda permiten interpretar patrones funcionales vinculados a trayectorias tau.
- El pipeline es reproducible, segmentado y adaptable a cohortes clínicas reales.
- Las limitaciones actuales (variabilidad, tamaño, interpretabilidad) abren camino a integración multimodal con PET/LCR.

Conclusión: los modelos compactos permiten detectar alteraciones funcionales en EEG clínico, con potencial como biomarcadores no invasivos vinculados a tau.

Future work

- Extender el pipeline a más datasets clínicos con segmentación automática y validación por sujeto.
- Integrar conectividad funcional (PLV/PLI) y arquitecturas GCN para análisis de redes neuronales.
- Validar hallazgos funcionales con biomarcadores estructurales (PET tau, LCR tau) si están disponibles.
- Explorar modelos multimodales que combinen EEG + tau + metadatos clínicos (MMSE, MoCA).
- Optimizar entrenamiento clínico con AMP y batch tuning para escalabilidad en cohortes grandes.
- Publicar mapas de saliencia por canal/banda como herramienta de interpretabilidad clínica.

Academic Products

- **Monografía** sobre biomarcadores EEG funcionales en demencia.
- **Repositorio GitHub** con código reproducible, segmentación automática, entrenamiento AMP y comparaciones por sujeto.
github.com/ivansst773/EEGNet_ShallowConvNet_Monografia
- **Presentación interactiva en Streamlit Viewer** con visualizaciones, métricas y mapas por canal/banda.
[streamlit.io/view/...](https://streamlit.io/view/)
- **Bitácora técnica** documentada por fecha, sujeto, modelo y configuración.
[bitacora.md](#)
- **Diagramas metodológicos en TikZ** con color institucional y narrativa clara.
- **Resultados clínicos validados** con EEGNet y ShallowConvNet sobre cohortes CN/MCI/AD.

Todos los productos están disponibles públicamente para consulta, validación y extensión futura.



Acknowledgements

- Universidad Nacional de Colombia – Sede Manizales, por el respaldo académico y técnico.
- Grupo de investigación, por el acompañamiento metodológico.
- Profesor Andrés Marino Álvarez Meza, PhD, por su invaluable guía científica, clínica y computacional, así como por su constante apoyo en el ámbito académico y personal durante todo el proceso.
- Comunidad académica y compañeros de semillero, por el intercambio de ideas y validación de resultados.
- Familia, por el apoyo constante durante todas las etapas del proyecto.

Este trabajo es resultado de un esfuerzo colectivo, técnico y humano, con impacto académico y clínico.

Acknowledgements

¡Gracias!

Este trabajo representa un paso hacia biomarcadores EEG funcionales accesibles, reproducibles y clínicamente relevantes.

Edgar Iván Calpa Cuacialpud

Universidad Nacional de Colombia – Sede Manizales

eicalpac@unal.edu.co

github.com/ivansst773/EEGNet_ShallowConvNet_Monografia

References |

- Ajra, H., et al. (2023). Deep learning-based EEG connectivity analysis for differential diagnosis of Alzheimer's and frontotemporal dementia. *Frontiers in Aging Neuroscience*.
- Ajra, Z., Xu, B., Dray, G., Montmain, J., & Perrey, S. (2023). Using shallow neural networks with functional connectivity from EEG signals for early diagnosis of Alzheimer's and frontotemporal dementia. *Frontiers in Neurology*, 14.
<https://doi.org/10.3389/fneur.2023.1270405>
- Blankertz, B., et al. (2008a). BCI Competition IV.
- Blankertz, B., Müller, K.-R., Curio, G., Vidaurre, C., Schlogl, A., et al. (2008b). BCI Competition IV: Results and perspectives. *Proceedings of the NIPS 2008 Workshop on BCI*, 1-6. <https://www.bbci.de/competition/iv/>
- de Paula, V. J. R., Guimarães, F. M., Diniz, B. S., & Forlenza, O. V. (2009). Neurobiological pathways to Alzheimer's disease: Amyloid-beta, tau protein or both. *Dementia & Neuropsychologia*, 3(3), 188-194.
<https://doi.org/10.1590/S1980-57642009DN30300005>
- de Paula, V., et al. (2009). Tau pathology in Alzheimer's disease and other tauopathies. *Journal of Alzheimer's Disease*.
- Gil-González, A., et al. (2023a). A Dataset of Scalp EEG Recordings of Alzheimer's Disease, Frontotemporal Dementia and Healthy Subjects from Routine EEG. *Data*, 8(6), 95.

References II

- Gil-González, A., Álvarez-Meza, A., Lotero, B., Triana-Martínez, J., et al. (2023b). A Dataset of Scalp EEG Recordings of Alzheimer's Disease, Frontotemporal Dementia and Healthy Subjects from Routine EEG. *Data*, 8(6), 95. <https://doi.org/10.3390/data8060095>
- Kay, S. M. (1998). *Fundamentals of Statistical Signal Processing, Volume II: Detection Theory*. Prentice Hall. <https://www.worldcat.org/title/39135645>
- Lawhern, V. J., Solon, A. J., Waytowich, N. R., Gordon, S. M., Hung, C. P., & Lance, B. J. (2018a). EEGNet: a compact convolutional neural network for EEG-based brain-computer interfaces. *Journal of Neural Engineering*, 15(5), 056013. <https://doi.org/10.1088/1741-2552/aace8c>
- Lawhern, V. J., Solon, A. J., Waytowich, N. R., Gordon, S. M., Hung, C. P., & Lance, B. J. (2018b). EEGNet: A compact convolutional neural network for EEG-based brain-computer interfaces. *Journal of neural engineering*, 15(5), 056013.
- Schirrmeister, R. T., Springenberg, J. T., Fiederer, L. D. J., Glasstetter, M., Eggensperger, K., Tangermann, M., Hutter, F., Burgard, W., & Ball, T. (2017a). Deep learning with convolutional neural networks for EEG decoding and visualization. *Human Brain Mapping*, 38(11), 5391-5420. <https://doi.org/10.1002/hbm.23730>

References III

- Schirrmeister, R. T., Springenberg, J. T., Fiederer, L. D. J., Glasstetter, M., Eggensperger, K., Tangermann, M., Hutter, F., Burgard, W., & Ball, T. (2017b). Deep learning with convolutional neural networks for EEG decoding and visualization. *Human brain mapping*, 38(11), 5391-5420.
- Tolnay, M., & Probst, A. (1999). Tau protein pathology in Alzheimer's disease and related disorders. *Neuropathology and Applied Neurobiology*, 25(3), 171-187.
<https://doi.org/10.1046/j.1365-2990.1999.00188.x>