

# EEGNet y Shallow ConvNet

Universidad Nacional de Colombia - Sede Manizales  
Edgar Iván Calpa

Modelos de aprendizaje profundo aplicados a señales EEG  
Profesor: Andrés Marino Álvarez Meza, PhD  
Departamento de Ingeniería Eléctrica, Electrónica y Computación



# Outline

- 1 Motivation
- 2 Problem Statement
- 3 State of the art
- 4 Objectives
- 5 Methodology
- 6 Results
- 7 Conclusions

# Motivation

- **Accesibilidad clínica:** PET tau y LCR son costosos e invasivos, se requiere biomarcador no invasivo y repetible [de Paula et al., 2009]
- **Huella funcional:** La propagación de tau altera ritmos y conectividad neuronal, el EEG puede capturar esos cambios [Tolnay y Probst, 1999]
- **Deep learning en EEG:** Modelos compactos como EEGNet y Shallow ConvNet detectan patrones espacio-temporales en EEG con datos limitados [Lawhern et al.; Schirrmeyer et al., 2018, 2017]

# Problem Statement

- **General:** No existe un biomarcador funcional, no invasivo y accesible para detectar progresión de Alzheimer vinculada a tau [de Paula et al., 2009]
- **Específico:** Validar si EEGNet y Shallow ConvNet identifican patrones EEG asociados a propagación de tau y progresión clínica [Lawhern et al.; Schirrneister et al., 2018, 2017]
- **Qué hacemos:** Entrenar y comparar ambos modelos sobre EEG CN/MCI/AD, analizar interpretabilidad por canal/banda y vincular hallazgos con trayectorias tau [Ajra et al., 2023]

# Problem Statement

- **Teoría de detección:** Maximizar  $P_D$  para un  $P_{FA}$  dado, evaluar curvas ROC y umbrales [Kay, 1998]
- **Neurobiología de tau:** Hiperfosforilación, ovillos neurofibrilares y patrón hipocampo→entorhinal→cortezas asociativas [Tolnay y Probst, 1999]
- **Implicación EEG:** Cambios en alfa/beta/gamma y sincronización funcional reflejan la disrupción de redes por tau [de Paula et al., 2009]

# State of the art

- **EEGNet**: CNN compacta con convoluciones separables, generaliza con pocos datos [Lawhern et al., 2018]
- **Shallow ConvNet**: Arquitectura superficial para ritmos mu/beta, baseline reproducible en BCI [Schirrneister et al., 2017]
- **Demencia + conectividad**: Shallow CNN con AEC/PLV para AD vs FTD vs controles, alta exactitud [Ajra et al., 2023]
- **Brecha**: Falta conexión directa entre deep-EEG y biomarcadores tau [de Paula et al., 2009]

- **Innovación:** Unir neurobiología de tau con detección funcional en EEG mediante CNN compactas [Ajra et al.; Lawhern et al., 2023, 2018]
- **Etiqueta del estudio:** Biomarcador EEG funcional para progresión de Alzheimer
- **Métricas:** Accuracy, F1 macro, AUC ROC,  $P_D$ ,  $P_{FA}$ ; mapas de importancia por canal/banda [Kay, 1998]

# Objectives

- **General:** Desarrollar y validar un modelo EEG (EEGNet vs Shallow) para detectar patrones asociados a tau y progresión de Alzheimer

[Lawhern et al.; Schirrneister et al., 2018, 2017]

- **Específicos:**

- Preprocesar EEG CN/MCI/AD y segmentar ventanas 2–4 s [Schirrneister et al., 2017]
- Entrenar y comparar EEGNet vs Shallow ConvNet en clasificación CN vs AD y CN vs MCI [Lawhern et al., 2018]
- Interpretabilidad: analizar bandas y canales relevantes y su coincidencia con trayectorias tau [Ajra et al., 2023]
- Validar con severidad clínica (MMSE/MoCA) y, si hay, PET/LCR tau [de Paula et al., 2009]



# Experimental design

- **Datos:** EEG multicanal CN/MCI/AD con metadatos clínicos; subcohorte PET/LCR si está disponible [Ajra et al., 2023]
- **Entradas:** Señales EEG ( $C \times T$ ), ventanas 2–4 s, normalización; opcional espectrogramas y matrices PLV/PLI [Lawhern et al.; Schirrneister et al., 2018, 2017]
- **Sensor:** Sistema 10–20 clínico (32–64 canales) [Schirrneister et al., 2017]
- **Metodología:**
  - Clásicos: PSD, PLV/PLI + SVM/LDA, curvas ROC [Kay, 1998]
  - IA: EEGNet y Shallow ConvNet; opcional GCN sobre conectividad [Ajra et al.; Lawhern et al., 2023, 2018]
- **Validación:** k-fold por sujeto; métricas accuracy, F1, AUC,  $P_D$ ,  $P_{FA}$ ; mapas de saliencia [Kay; Lawhern et al., 1998, 2018]


# Papers on EEG mapping with AI

- **Lawhern et al. 2018 (EEGNet):** Multi-paradigma BCI, AUC/kappa, compacto, sensible al preprocesamiento [Lawhern et al., 2018]
- **Schirrmeister et al. 2017 (Shallow/DeepConvNet):** BCI IV-2a, intra- y cross-subject, baseline reproducible, necesita ajuste [Schirrmeister et al., 2017]
- **Ajra et al. 2023 (Demencia + conectividad):** EEG clínico AD/FTD vs HC, AEC/PLV, alta exactitud, falta vínculo con tau [Ajra et al., 2023]

# Datasets

- EEG clínico CN/MCI/AD (32–64 canales, sistema 10-20).
- Subcohorte con PET/LCR tau (si disponible).
- Validación cruzada por sujeto.

# Methodology



# Expected Results

- Métricas: Accuracy, F1, AUC, PD, PFA.
- Mapas de saliencia por canal/banda.
- Comparación EEGNet vs Shallow ConvNet.

# Limitations

- Variabilidad inter-sujeto en EEG.
- Tamaño reducido de dataset.
- Interpretabilidad limitada de CNN.

# Conclusions

- EEGNet y Shallow ConvNet son candidatos viables para biomarcadores EEG funcionales.
- Posible vínculo con trayectorias tau.

# Future work

- Extender a más datasets clínicos.
- Integrar conectividad avanzada (PLV/PLI, GCN).
- Validar con biomarcadores PET/LCR.



# Academic products

- 1 Monografía de grado.
- 2 Repositorio GitHub con código y datos.
- 3 Presentaciones y bitácora.

# Acknowledgements

- Universidad Nacional de Colombia.
- Grupo de investigación.
- Profesor Andrés Marino Álvarez Meza, PhD.

# References I

- Ajra, Z., Xu, B., Dray, G., Montmain, J., & Perrey, S. (2023). Using shallow neural networks with functional connectivity from EEG signals for early diagnosis of Alzheimer's and frontotemporal dementia. *Frontiers in Neurology*, 14.  
<https://doi.org/10.3389/fneur.2023.1270405>
- de Paula, V. J. R., Guimarães, F. M., Diniz, B. S., & Forlenza, O. V. (2009). Neurobiological pathways to Alzheimer's disease: Amyloid-beta, tau protein or both. *Dementia & Neuropsychologia*, 3(3), 188-194.  
<https://doi.org/10.1590/S1980-57642009DN30300005>
- Kay, S. M. (1998). *Fundamentals of Statistical Signal Processing, Volume II: Detection Theory*. Prentice Hall. <https://www.worldcat.org/title/39135645>
- Lawhern, V. J., Solon, A. J., Waytowich, N. R., Gordon, S. M., Hung, C. P., & Lance, B. J. (2018). EEGNet: a compact convolutional neural network for EEG-based brain-computer interfaces. *Journal of Neural Engineering*, 15(5), 056013.  
<https://doi.org/10.1088/1741-2552/aace8c>
- Schirrmeister, R. T., Springenberg, J. T., Fiederer, L. D. J., Glasstetter, M., Eggensperger, K., Tangermann, M., Hutter, F., Burgard, W., & Ball, T. (2017). Deep learning with convolutional neural networks for EEG decoding and visualization. *Human Brain Mapping*, 38(11), 5391-5420. <https://doi.org/10.1002/hbm.23730>

# References II

- Tolnay, M., & Probst, A. (1999). Tau protein pathology in Alzheimer's disease and related disorders. *Neuropathology and Applied Neurobiology*, 25(3), 171-187.  
<https://doi.org/10.1046/j.1365-2990.1999.00188.x>